

今晚的工作与核心 finding

从支撑关系排查，到材质恒常性三步实验

2026 年 7 月 18 日晚 - 7 月 19 日凌晨 | 内部阶段总结

一句话结论

我们找到了一个真实且可重复的问题：同一块材质只是换了灯光，VLM 就经常改变答案。但官方 albedo 模型虽然能把图像变得更稳定，冻结 VLM 却不会直接利用它。因此“零训练直接加提示”这条路线暂停。

今晚最重要的三个数字

跨光照翻转	两模型共同翻转	Albedo 像素波动
Qwen 57.58% InternVL 66.67%	34/66 个区域 51.52%	0.199 -> 0.083 65/66 区域改善

这个结果意味着什么

- 问题是存在的，而且不是某一个模型的偶然现象。
- 物理证据本身可以更稳定，但“怎么让 VLM 读懂”是真正的难点。
- 今晚没有得到一个可以直接写论文的方法，但成功定位了问题和无效接口，避免继续盲目投入。

1. 今晚实际做了哪些工作

整个过程不是直接跑一次模型，而是按“数据是否可用 - 问题是否存在 - 方法能否修复”逐层排查。

阶段	实际完成的工作	得到的判断
服务器与留痕	完成 SSH 密钥、校园网/GitHub 连通、个人工作区、GPU 3 使用与本地-远程同步。	后续实验可复现，不触碰服务器其他人目录。
Support 关系 pilot	下载并校验 NYUv2；从 1,449 帧中构造 167 个候选，人工检查 14 个。	仅 2 个是支撑，11 个不是，1 个不确定；数据不适合规模化做真值。
方向查重与转向	核验 InstaFormer 等相关工作，排除遮挡文本提示的高重合路线；审计材质恒常性数据。	选择“光照变化下的 VLM 材质稳定性”作为低成本验证项。
三步材质实验	从 23 区域 pilot 扩到 66 区域/330 样本，复核两个 VLM，再运行 Marigold IID 和三种干预接口。	确认 RGB-only 故障，但零训练 albedo 干预未通过。

为什么 Support 方向要停

深度和实例框可以帮我们找到“上下靠得很近”的物体，但这不等于它们真的直接接触和支撑。隔板、柜子、大物体 mask 等都会产生高分误报。继续人工标注成本很高，而正例又很少，所以及时停损比继续堆数据更合理。

这部分不是白做

它让我们在只人工审核 14 个样本时就发现数据根本限制，避免了将数百个几何候选误当成真实支撑关系。

2. 材质恒常性：问题是真的

材质恒常性可以简单理解为：同一个物体换了灯光，我们仍应判断它是同一种材质。实验中的物体、位置和材质都不变，只改变真实灯光。

实验步骤	数据规模	结果	判断
第一步小 pilot	10 场景 23 区域 115 张图	Qwen 翻转 47.83%	问题初步存在
第二步扩展复核	30 场景 66 区域 330 张图	Qwen 57.58% InternVL 66.67%	两个模型都存在
两模型共同失败	同一批 66 区域	34/66 同时翻转	不是 Qwen 的偶然问题




图1 同一 330 个样本在不同证据接口下的表现（翻转率越低越好，但必须同时看准确率）

如何理解“翻转”

如果同一块布在 5 种灯光下，模型有 4 次说“布料”、1 次说“瓷砖”，这个区域就算发生过翻转。这个指标不只看某一张图答对没有，而是看模型对同一材质是否稳定。

已验证的 finding

在有明显照明差异的压力测试中，冻结 VLM 的材质答案会大量随灯光变化；且两个不同系列的 2B 模型在容易翻转的区域上高度重合。

3. Albedo 干预：图像稳定了，VLM 却没有变好

Albedo 可以理解为尽量去掉灯光影响后的表面固有外观。我们使用官方 Marigold IID Appearance v1.1，先处理 247 张完整场景-光照图，再按原坐标裁剪，避免直接对小图分解带来假结果。




图 2 同一张室内场景：左为 RGB，右为 Marigold albedo

输入方式	Qwen 准确率 / 翻转	InternVL 准确率 / 翻转	结论
RGB 基线	60.30% / 57.58%	53.03% / 66.67%	对照组
Albedo-only	36.36% / 71.21%	29.39% / 77.27%	更差
RGB + Albedo	61.21% / 50.00%	51.21% / 65.15%	无稳定收益
RGB + 物理数值	36.67% / 36.36%	25.15% / 36.36%	伪一致性

最关键的反例

把 Marigold 预测的粗糙度和金属度写成文本后，两个模型确实“更稳定”了，但 Qwen 有 227/330 次、InternVL 有 269/330 次直接回答“metal”。这种稳定是因为它们反复答同一个错误类别，不是真正理解了材质。

第三步决策：No-Go

“直接给 albedo 图”和“直接给物理数值文本”都没有在两个模型上同时提高准确率和稳定性。按实验前设定的停损标准，这条零训练路线暂停。

4. 今晚的最终 finding 与建议

可以较有把握地说

- 冻结 VLM 的材质判断对真实灯光变化很敏感，该现象已在 Qwen 和 InternVL 上重复。
- Marigold 生成的 albedo 确实更稳定，说明“消除照明干扰”这个物理出发点没有问题。
- 真正的瓶颈是 VLM 不会直接使用本征图或物理数值，存在明显的“物理证据-模型接口”鸿沟。

现在还不能说

- 还不能说我们已经有了一个可发表的新方法。
- 还不能把压力测试中的 57%-67% 翻转率，理解为日常随机灯光下的自然发生概率。
- 只测了 2B 级模型，且 clear plastic、marble 等类别仍较少，还不能外推到所有 VLM。

建议怎么处理这条线

建议：归档当前零训练方案，不再继续堆实验

如果组里希望继续，研究问题必须升级为“如何学习 albedo/材质属性与 VLM 之间的对齐接口”，例如轻量 adapter 或微调。这会明显增加数据、训练和查重成本，不再是原先预期的低成本 DOP 式课题。

今晚留下的可复现材料

材料	已保存内容	位置
数据与 manifest	66 区域、330 样本、两个本征证据 manifest	local/multimodal-research/experiments
模型预测	RGB、albedo、RGB+albedo、物理文本的逐样本输出	local/multimodal-research/results
脚本和配置	数据构建、Qwen/InternVL 推理、Marigold、bootstrap 分析	local/multimodal-research/scripts / configs
运行日志	下载、环境、全量推理与结果哈希	local/multimodal-research/experiments/logs

备注：这份文档是内部阶段汇报。所有结果都保留了配置、逐样本预测、日志和本地-远程哈希；数据和权重不进 Git。